

Sonar Municipal: Descoberta, Organização e Busca Semântica de Projetos de Lei Municipais para Apoio à Formulação de Políticas Públicas

Thiago Ambiel¹, André C. P. L. F. de Carvalho¹

¹Instituto de Ciências Matemáticas e de Computação – Universidade de São Paulo (USP)
São Carlos – SP – Brazil

thiago.ambiel@usp.br, andre@icmc.usp.br

Resumo. Gestores municipais frequentemente precisam redigir Projetos de Lei (PLs) com pouco tempo e pouca visibilidade sobre soluções já propostas em outros municípios. Este artigo apresenta um sistema reprodutível para descobrir instâncias brasileiras do SAPL, extrair PLs municipais, traduzir ementas em ações textualizadas, recuperar propostas semelhantes por busca semântica e relacionar políticas recorrentes a indicadores oficiais municipais. Em uma execução congelada em 12 de novembro de 2025, o pipeline encontrou 1.259 instâncias do SAPL, obteve extração válida em 322 delas e coletou 220.065 PLs de 322 municípios distribuídos em 19 UFs. O acervo é extenso, mas ainda não representa o universo nacional da produção legislativa municipal. O tradutor ementa → ação foi treinado com 1.000 pares sintéticos derivados de ementas reais e atingiu BERTScore de 84% no conjunto de validação.

Palavras-chave: Projetos de Lei municipais; SAPL; governo digital; busca semântica; textualização de ementas; indicadores municipais

1. Introdução

A formulação de políticas públicas municipais no Brasil ocorre em um ambiente de forte heterogeneidade institucional, textual e tecnológica. Municípios com problemas semelhantes produzem proposições com vocabulário distinto, diferentes níveis de detalhamento e portais legislativos com graus variados de padronização, o que dificulta a reutilização de experiências anteriores e limita o uso sistemático de evidências legislativas no processo decisório.

Este trabalho investiga se é possível transformar o histórico de Projetos de Lei municipais em um acervo pesquisável de ações públicas orientadas a problema, integrando textos legislativos, recuperação semântica e indicadores oficiais. A pergunta central é a seguinte: *é possível construir um pipeline reprodutível para descoberta, organização e apoio exploratório à identificação de políticas públicas similares a partir de PLs históricos e indicadores oficiais?*

O artigo se posiciona como um trabalho de sistema aplicado a governo digital. Suas principais contribuições são: um método reprodutível para descoberta de instâncias do SAPL e extração automatizada de PLs em escala nacional; uma estratégia de textualização de ementas em ações textualizadas para reduzir ruído linguístico; um mecanismo de busca semântica em linguagem natural para apoiar a identificação de políticas similares;

e um procedimento exploratório de associação entre grupos de PLs e indicadores municipais oficiais. A implementação atual deve ser lida como uma infraestrutura concreta e reproduzível sobre um acervo interestadual parcial, com coleta e tradução mais maduras do que recuperação, agrupamento e análise com indicadores.

O restante do artigo organiza a proposta em cinco etapas: descoberta de fontes, extração de PLs, textualização de ementas, busca semântica e associação exploratória com indicadores municipais.

2. Trabalhos Relacionados

O problema tratado neste artigo dialoga com três frentes principais: a infraestrutura legislativa aberta no Brasil, especialmente o SAPL e o ecossistema do Interlegis [1]; a recuperação de informação em documentos legislativos e jurídicos brasileiros, com estudos sobre stemming, BM25, pipelines de recuperação e *relevance feedback* no nível federal [2, 3, 4]; e a literatura de difusão e transferência de políticas públicas, que fundamenta a utilidade de comparar proposições entre cidades [5]. Em paralelo, recursos como UlyssesNER-Br mostram amadurecimento do ecossistema brasileiro de NLP jurídico [6].

Essas linhas são relevantes, mas ainda insuficientes para o cenário municipal, em que o desafio começa antes da busca: é necessário descobrir fontes, lidar com heterogeneidade de portais, extrair dados em escala e normalizar textos legislativos curtos e ruidosos. A principal contribuição do Sonar Municipal é integrar descoberta automatizada de fontes, extração, textualização, busca semântica e associação exploratória com indicadores em um único pipeline orientado ao nível municipal.

3. Materiais e Métodos

3.1. Visão geral

O pipeline possui cinco etapas: (i) descoberta de instâncias do SAPL a partir da lista de municípios do IBGE [7]; (ii) extração de Projetos de Lei diretamente das APIs públicas; (iii) textualização de ementas; (iv) indexação vetorial para busca semântica; e (v) associação exploratória com indicadores municipais e agrupamento de políticas similares. A Figura 1 sintetiza esse fluxo da descoberta das fontes à interface pública.

3.2. Descoberta e extração

A descoberta combina heurísticas de URL com validação por evidência pública. Para cada município, o sistema gera endereços candidatos com base no nome normalizado do município e na sigla da unidade federativa, testa rotas típicas do SAPL e valida a instância quando encontra marcadores compatíveis. Em seguida, a extração deriva a base correta da API, consulta os tipos de matéria e percorre a paginação de todos os tipos cujo rótulo contém “projeto de lei”.

Na execução congelada em 12 de novembro de 2025, foram encontradas 1.259 instâncias do SAPL, das quais 322 permitiram extração válida com ao menos um PL, totalizando 220.065 registros. Considerando os 5.570 municípios brasileiros, isso corresponde a 22,60% de cobertura na descoberta e 5,78% na extração automatizada. A diferença entre essas etapas reflete heterogeneidade técnica entre portais, mudanças de rota, autenticação e diferenças locais de configuração. Assim, a descoberta operou em

Pipeline do Sonar Municipal

Da descoberta de fontes à interface pública de busca e exploração de políticas similares




Figura 1. Síntese do pipeline do Sonar Municipal, da descoberta de fontes à interface pública.

escopo nacional, mas a base extraída deve ser interpretada como um subconjunto parcial e desigual dos municípios com instâncias SAPL acessíveis.

A base final cobre 322 municípios em 19 UFs. Todos os registros possuem ementa, ação, endereço público de origem e representação vetorial preenchidos. A base não apresentou duplicatas nem no endereço público nem na combinação entre a instância SAPL de origem e o identificador da matéria. O filtro textual de tipos, contudo, ainda recupera cerca de 3,54% de itens que não correspondem estritamente a PLs, como anteprojeto, emendas, substitutivos e vetos. Esses casos foram mantidos como ruído residual de coleta, sem a pretensão de que a base represente apenas PLs estritos.

3.3. Textualização de ementas

Para reduzir ruído jurídico e tornar as proposições mais comparáveis, cada ementa é convertida em uma ação textualizada no formato “verbo no infinitivo + objeto + complementos essenciais”. O conjunto de treinamento foi composto por 1.000 ementas reais distintas, textualizadas com apoio de GPT-5.1-Thinking [8] e revisadas manualmente nos casos em que houve perda de sentido.

Como modelo base, utilizou-se o PTT5-v2 [9], uma variante do T5 [10] adaptada ao português. O ajuste fino foi realizado com QLoRA em 4 bits [11], com divisão 90/10 entre treino e validação, 30 épocas, taxa de aprendizado de 3×10^{-4} e tamanho de lote igual a 16. A avaliação automática por BERTScore [12] atingiu 84% no conjunto de validação.

No acervo completo, a tradução reduziu o comprimento médio das descrições de 152,86 para 90,01 caracteres e de 24,18 para 13,61 palavras. Isso corresponde a 58,9% dos caracteres e a 56,3% das palavras das ementas originais, o que favorece busca e agrupamento. A textualização foi mantida por três razões operacionais. Primeiro, o modelo de

representações vetoriais não foi treinado especificamente em texto legislativo. Segundo, ações curtas são mais legíveis para o usuário final do que ementas jurídicas. Terceiro, o agrupamento por similaridade textual tende a funcionar melhor quando há menos ruído introduzido por fórmulas legislativas recorrentes.

3.4. Busca, indicadores e agrupamento

As ações são indexadas com representações vetoriais do modelo Multilingual E5 [13] e armazenadas no Qdrant [14]. As consultas seguem o formato recomendado pelo modelo para entradas de busca. A avaliação da recuperação ainda é inicial. Foi realizada inspeção manual das primeiras posições e uma avaliação preliminar com consultas públicas de demonstração, mas ainda não há benchmark anotado nem métricas formais como Precision@K ou nDCG.

Para aproximar o sistema de desfechos observáveis, utilizamos taxa de homicídios por 100 mil habitantes e taxa de matrículas em ensino regular por 100 mil habitantes. As variações são calculadas comparando o indicador na data mais próxima ao PL com janelas posteriores de 6, 12, 18, 24, 30 e 36 meses. Trata-se de uma análise descritiva, sem pretensão causal, utilizada apenas para priorização exploratória de políticas recorrentes.

PLs semanticamente próximos são agrupados por similaridade de Jaccard sobre o texto da ação, com limiar 0,75. Para cada grupo, definimos o seguinte escore heurístico:

$$Q = \frac{p}{n} \times \frac{n}{n+1}$$

em que n é o número de municípios representados e p é o número de casos com variação favorável ao objetivo do indicador. O termo final penaliza grupos muito pequenos e ajuda a priorizar políticas mais recorrentes.

3.5. Implementação

A plataforma foi implementada em React/Next.js e integra interface web, serviço de geração de representações vetoriais, banco vetorial e dados de indicadores [15]. O código de coleta, treinamento, indexação e interface permanece disponível em <https://github.com/thiagoambiel/SonarMunicipal>, juntamente com o prompt do tradutor e a lista congelada de instâncias SAPL utilizadas no artigo. A implementação web pública está disponível em <https://sonar-municipal.vercel.app/>. A reprodução integral do acervo depende da disponibilidade externa das APIs públicas no momento da coleta, mas o repositório documenta as etapas e disponibiliza os artefatos necessários para reexecução.

4. Resultados

4.1. Cobertura da base

A execução congelada indica que a descoberta nacional é tecnicamente viável, mas que a extração automatizada ainda depende fortemente da qualidade e da estabilidade das instâncias municipais do SAPL. A Figura 2 resume os principais números dessa execução como painel visual de escala, redução e concentração regional.



Figura 2. Painel visual da execução congelada, combinando indicadores-chave, redução do pipeline e distribuição regional do acervo final.

Em termos percentuais, o Sul concentra 45,52% dos registros e o Sudeste, 23,03%; juntas, essas duas regiões somam 68,55% do acervo e 64,29% dos municípios cobertos. A Figura 2 antecipa essa leitura quantitativa, e a Figura 3 mostra sua distribuição territorial, com cobertura concentrada em 19 UFs e lacunas visíveis em parte do Norte e do Nordeste. O resultado deve ser interpretado como um acervo interestadual extenso, mas não como um espelho nacional da produção legislativa municipal. A base cobre principalmente o período recente da produção legislativa: entre 2021 e 2025, há 96.018 registros distribuídos por 315 municípios. Também foram observados poucos outliers temporais, o que indica necessidade de saneamento antes de análises mais sensíveis ao eixo cronológico.

4.2. Tradução e busca semântica

Viabilidade da textualização. Na avaliação interna do projeto, o tradutor *ementa* → *ação* obteve BERTScore de 84% no conjunto de validação. A transformação de todo o acervo de 220.065 PLs em ações textualizadas levou 4h47min na execução reportada, o que indica viabilidade operacional nessa escala.

A análise exploratória da base mostrou que a textualização reduz substancialmente o comprimento médio das descrições legislativas sem eliminar a diversidade do acervo. Foram observadas 219.245 ementas únicas e 188.254 ações textualizadas únicas. Em termos práticos, a transformação encurta o texto e reduz variabilidade superficial suficiente para favorecer recuperação semântica e agrupamento; exemplos típicos incluem conversões como “Institui o Plano Municipal de Saneamento Básico” para “Criar plano municipal de saneamento básico”.

Utilidade preliminar da busca. A etapa de busca semântica foi avaliada de forma exploratória com consultas reais e julgamento manual preliminar das ações retornadas. Em




Figura 3. Cobertura territorial da base final por UF. Estados em cinza não tiveram extração válida na execução congelada; a intensidade do azul indica o número de municípios cobertos em cada UF.

uma inspeção das cinco consultas públicas de demonstração disponíveis no sistema, 17 dos 25 itens retornados entre os cinco primeiros resultados foram julgados diretamente alinhados ao tema da consulta. Os melhores resultados apareceram em saneamento e evasão escolar, enquanto a consulta sobre arrecadação sem aumento de impostos apresentou o pior desempenho.

Mesmo sem benchmark anotado, a busca produz resultados tematicamente coerentes em consultas substantivas. Para a consulta “como enfrentar a violência contra a mulher no município?”, por exemplo, a recuperação semântica retornou entre os primeiros itens ações como: regulamentar a violência contra a mulher no município (Uruguai-ana/RS), criar política municipal de enfrentamento à violência política contra a mulher (Parauapebas/PA) e promover campanha de denúncia da violência contra a mulher (Anápolis/GO).

4.3. Estudo de caso: violência contra a mulher

Entre os temas disponíveis no acervo, violência contra a mulher foi selecionado como estudo de caso principal. O recorte lexical correspondente reúne 2.306 ações distribuídas por 204 municípios e 18 UFs. Esse volume foi considerado adequado para ilustrar o fluxo completo do sistema, desde a consulta em linguagem natural até a consolidação de políticas recorrentes. A Figura 4 sintetiza esse percurso visualmente. Por razões de disponibilidade e cobertura, adotou-se a taxa de homicídios como proxy inicial deste estudo de caso, exclusivamente para fins exploratórios de priorização.

No recorte temático com janela de 6 meses para taxa de homicídios, 1.240 ações tiveram variação computável e geraram 136 políticas agrupadas com pelo menos dois municípios. O cluster com maior escore heurístico foi “Conceder auxílio financeiro a mulheres vítimas de violência doméstica no município”, com $Q = 0,778$, oito municí-

Fluxo do estudo de caso: violência contra a mulher




Figura 4. Fluxo completo do estudo de caso sobre violência contra a mulher, da consulta em linguagem natural à priorização exploratória de políticas recorrentes.

pios representados e sete variações favoráveis em oito observações. Entre os exemplos que compõem esse grupo estão Marabá, Campina Grande e Campinas, com reduções observadas de -26,23%, -22,22% e -30,00%, respectivamente. Esses resultados devem ser interpretados como associações observadas após a proposição legislativa, e não como evidência causal de efetividade.

Além do cluster líder, o estudo de caso indica diversidade de estratégias. Entre os grupos com $Q = 0,750$, apareceram propostas de tramitação prioritária para processos envolvendo vítimas de violência doméstica, programas de defesa pessoal para mulheres, programas municipais de enfrentamento ao feminicídio e mecanismos de punição administrativa para autores de violência contra a mulher. Também apareceu um grupo educacional recorrente: ensino de noções básicas sobre a Lei Maria da Penha nas escolas municipais, com oito municípios e $Q = 0,667$. A Figura 5 organiza esse conjunto como mosaico visual de respostas recorrentes.

4.4. Falhas observadas


A inspeção qualitativa apontou dois riscos recorrentes. Na textualização, a condensação pode alterar o sentido material da proposta quando o modelo força uma paráfrase inadequada, como em "Junho Violeta" → "Junho Violento". Nos indicadores, variações de -100% em janelas futuras com contagem zero podem parecer excessivamente favoráveis em municípios pequenos ou com baixa contagem absoluta de eventos.

5. Limitações e Ameaças à Validade

O trabalho apresenta quatro limitações principais. Primeiro, a cobertura da coleta depende da infraestrutura digital das câmaras municipais, o que introduz viés regional e institucional. Segundo, a avaliação do tradutor ainda carece de *baselines* mais fortes, conjunto

Estratégias recorrentes identificadas no estudo de caso

O sistema recupera respostas econômicas, educacionais, administrativas e protetivas.



Diversidade de estratégias, sem concentração em uma única família de resposta.

Figura 5. Estratégias recorrentes identificadas no estudo de caso, destacando o cluster líder e a diversidade de respostas econômicas, educacionais, administrativas e protetivas.

de teste independente e comparação sistemática com o uso direto das ementas originais. Terceiro, a busca semântica ainda não dispõe de benchmark anotado nem de métricas formais de recuperação. Quarto, a análise com indicadores é observacional, sensível à qualidade temporal da base e insuficiente para sustentar inferência causal. A proxy educacional baseada em matrículas, o uso de homicídios no estudo de caso, o agrupamento textual por Jaccard e o ruído residual da base devem ser entendidos como simplificações de uma avaliação inicial. Em uso institucional, o sistema deve funcionar apenas como apoio exploratório, com validação humana e contextualização local antes de qualquer adoção, adaptação ou priorização administrativa.

6. Conclusão

Este artigo apresentou uma infraestrutura reprodutível para descoberta de instâncias do SAPL, extração de PLs, tradução de ementas em ações textualizadas, busca semântica e associação exploratória com indicadores oficiais municipais. Na execução congelada de 12 de novembro de 2025, o sistema encontrou 1.259 instâncias do SAPL, extraiu PLs de 322 delas e reuniu um acervo de 220.065 proposições distribuídas por 322 municípios e 19 UFs. Os resultados demonstram viabilidade técnica para descoberta em escopo nacional, textualização em escala e utilidade preliminar da busca semântica em consultas públicas de demonstração. O próximo passo é fortalecer a validação com benchmark formal de recuperação, *baselines* mais fortes para o tradutor e maior controle sobre ruídos da base e das métricas observacionais.

Referências

- [1] Senado Federal e Programa Interlegis. *Sistema de Apoio ao Processo Legislativo (SAPL)*. URL: <https://www12.senado.leg.br/interlegis/produtos/sapl> (acesso em 07/01/2026).

- [2] Ellen Souza et al. “Assessing the Impact of Stemming Algorithms Applied to Brazilian Legislative Documents Retrieval”. Em: *Proceedings of the 13th Brazilian Symposium in Information and Human Language Technology*. Porto Alegre, Brazil: Association for Computational Linguistics, 2021, pp. 227–236. URL: <https://aclanthology.org/2021.stil-1.25/> (acesso em 15/03/2026).
- [3] Ellen Souza et al. “An Information Retrieval Pipeline for Legislative Documents from the Brazilian Chamber of Deputies”. Em: *Legal Knowledge and Information Systems*. Vol. 346. Frontiers in Artificial Intelligence and Applications. IOS Press, 2021, pp. 119–126. DOI: 10.3233/FAIA210326. URL: <https://doi.org/10.3233/FAIA210326> (acesso em 15/03/2026).
- [4] Douglas Vitória et al. “Building a Relevance Feedback Corpus for Legal Information Retrieval in the Real-Case Scenario of the Brazilian Chamber of Deputies”. Em: *Language Resources and Evaluation* 59.2 (2025), pp. 1257–1277. DOI: 10.1007/S10579-024-09767-3. URL: <https://dblp.org/rec/journals/lre/VitorioSMSCOA25> (acesso em 15/03/2026).
- [5] Charles R. Shipan e Craig Volden. “The Mechanisms of Policy Diffusion”. Em: *American Journal of Political Science* 52.4 (2008), pp. 840–857. DOI: 10.1111/j.1540-5907.2008.00346.x.
- [6] Hidelberg Oliveira Albuquerque, Rosimeire Costa, Gabriel Dalforno Silvestre et al. “UlyssesNER-Br: A Corpus of Brazilian Legislative Documents for Named Entity Recognition”. Em: *Computational Processing of the Portuguese Language: 15th International Conference, PROPOR 2022, Fortaleza, Brazil, March 21–23, 2022, Proceedings*. Vol. 13208. Lecture Notes in Computer Science. Springer, 2022, pp. 3–14. DOI: 10.1007/978-3-030-98305-5_1. URL: https://doi.org/10.1007/978-3-030-98305-5_1 (acesso em 15/03/2026).
- [7] IBGE. *API de Localidades (documentação)*. URL: <https://servicodados.ibge.gov.br/api/docs/localidades> (acesso em 07/01/2026).
- [8] OpenAI. *GPT-5.1 Model (OpenAI API)*. 2026. URL: <https://platform.openai.com/docs/models/gpt-5.1> (acesso em 07/01/2026).
- [9] Marcos Piau, Matheus P. Vieira et al. “PTT5-v2: A Closer Look at Continued Pretraining of T5 Models for the Portuguese Language”. Em: *arXiv* (2024). URL: <https://arxiv.org/abs/2406.10806> (acesso em 07/01/2026).
- [10] Colin Raffel et al. “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”. Em: *Journal of Machine Learning Research* 21.140 (2020), pp. 1–67. URL: <https://jmlr.org/papers/v21/20-074.html> (acesso em 07/01/2026).
- [11] Tim Dettmers et al. “QLoRA: Efficient Finetuning of Quantized LLMs”. Em: *arXiv* (2023). URL: <https://arxiv.org/abs/2305.14314> (acesso em 07/01/2026).
- [12] Tianyi Zhang et al. “BERTScore: Evaluating Text Generation with BERT”. Em: *arXiv* (2019). URL: <https://arxiv.org/abs/1904.09675> (acesso em 07/01/2026).

- [13] Liang Wang et al. “Multilingual E5 Text Embeddings: A Technical Report”. Em: *arXiv* (2024). URL: <https://arxiv.org/abs/2402.05672> (acesso em 07/01/2026).
- [14] Qdrant. *Qdrant Documentation*. URL: <https://qdrant.tech/documentation/> (acesso em 07/01/2026).
- [15] Vercel. *Next.js on Vercel (documentação)*. URL: <https://vercel.com/docs/frameworks/full-stack/nextjs> (acesso em 07/01/2026).