

Sonar Municipal: Descoberta, Organização e Busca Semântica de Projetos de Lei Municipais para Apoio à Formulação de Políticas Públicas

Thiago Ambiel¹, André C. P. L. F. de Carvalho¹

¹Instituto de Ciências Matemáticas e de Computação – Universidade de São Paulo (USP)
São Carlos – SP – Brazil

thiago.ambiel@usp.br, andre@icmc.usp.br

Resumo. Gestores municipais frequentemente precisam redigir Projetos de Lei (PLs) com pouco tempo e pouca visibilidade sobre soluções já propostas em outros municípios. Este artigo apresenta um sistema reprodutível para descobrir instâncias brasileiras do SAPL, extrair PLs municipais, traduzir ementas em ações textualizadas, recuperar propostas semelhantes por busca semântica e relacionar políticas recorrentes a indicadores oficiais municipais. Em uma execução congelada em 12 de novembro de 2025, o pipeline encontrou 1.259 instâncias do SAPL, obteve extração válida em 322 delas e coletou 220.065 PLs de 322 municípios distribuídos em 19 UFs. O acervo é extenso, mas ainda não representa o universo nacional da produção legislativa municipal. O tradutor ementa → ação foi treinado com 1.000 pares sintéticos derivados de ementas reais e atingiu BERTScore de 84% no conjunto de validação. Em uma avaliação automatizada por agente GPT-5.4, com 1.158 pares problema-documento distribuídos por 15 problemas e comparando bm25, ementas e ações, a recuperação baseada em ações apresentou o melhor desempenho, superando tanto BM25 quanto ementas em nDCG@10 (0,743 vs. 0,522 e 0,591), MAP@10 (0,173 vs. 0,125 e 0,142) e High-Recall@10 para documentos fortemente relevantes (0,215 vs. 0,145 e 0,165).

Palavras-chave: Projetos de Lei municipais; SAPL; governo digital; busca semântica; textualização de ementas; indicadores municipais

1. Introdução

A formulação de políticas públicas municipais no Brasil ocorre em um ambiente de forte heterogeneidade institucional, textual e tecnológica. Municípios com problemas semelhantes produzem proposições com vocabulário distinto, diferentes níveis de detalhamento e portais legislativos com graus variados de padronização, o que dificulta a reutilização de experiências anteriores e limita o uso sistemático de evidências legislativas no processo decisório.

Este trabalho investiga se é possível transformar o histórico de Projetos de Lei municipais em um acervo pesquisável de ações públicas orientadas a problema, integrando textos legislativos, recuperação semântica e indicadores oficiais. A pergunta central é a seguinte: *é possível construir um pipeline reprodutível para descoberta, organização e apoio exploratório à identificação de políticas públicas similares a partir de PLs históricos e indicadores oficiais?*

O artigo se posiciona como um trabalho de sistema aplicado a governo digital. Suas principais contribuições são: um método reproduzível para descoberta de instâncias do SAPL e extração automatizada de PLs em escala nacional; uma estratégia de textualização de ementas em ações textualizadas para reduzir ruído linguístico; um mecanismo de busca semântica em linguagem natural para apoiar a identificação de políticas similares; e um procedimento exploratório de associação entre grupos de PLs e indicadores municipais oficiais. A implementação atual deve ser lida como uma infraestrutura concreta e reproduzível sobre um acervo interestadual parcial, já acompanhada por uma avaliação anotada exploratória da recuperação. Essa avaliação permite sustentar comparações relativas entre representações textuais no benchmark considerado, mas ainda não autoriza conclusões fortes de generalização para todo o corpus ou para todos os domínios de política pública.

O restante do artigo organiza a proposta em cinco etapas: descoberta de fontes, extração de PLs, textualização de ementas, busca semântica e associação exploratória com indicadores municipais.

2. Trabalhos Relacionados

O problema tratado neste artigo dialoga com três frentes principais: a infraestrutura legislativa aberta no Brasil, especialmente o SAPL e o ecossistema do Interlegis [1]; a recuperação de informação em documentos legislativos e jurídicos brasileiros, com estudos sobre stemming, BM25, pipelines de recuperação e *relevance feedback* no nível federal [2, 3, 4]; e a literatura de difusão e transferência de políticas públicas, que fundamenta a utilidade de comparar proposições entre cidades [5]. Em paralelo, recursos como UlyssesNER-Br mostram amadurecimento do ecossistema brasileiro de NLP jurídico [6].

Essas linhas são relevantes, mas ainda insuficientes para o cenário municipal, em que o desafio começa antes da busca: é necessário descobrir fontes, lidar com heterogeneidade de portais, extrair dados em escala e normalizar textos legislativos curtos e ruidosos. A principal contribuição do Sonar Municipal é integrar descoberta automatizada de fontes, extração, textualização, busca semântica e associação exploratória com indicadores em um único pipeline orientado ao nível municipal.

3. Materiais e Métodos

3.1. Visão geral

O pipeline possui cinco etapas: (i) descoberta de instâncias do SAPL a partir da lista de municípios do IBGE [7]; (ii) extração de Projetos de Lei diretamente das APIs públicas; (iii) textualização de ementas; (iv) indexação vetorial para busca semântica; e (v) associação exploratória com indicadores municipais e agrupamento de políticas similares. A Figura 1 sintetiza esse fluxo da descoberta das fontes à interface pública.

3.2. Descoberta e extração

A descoberta combina heurísticas de URL com validação por evidência pública. Para cada município, o sistema gera endereços candidatos com base no nome normalizado do município e na sigla da unidade federativa, testa rotas típicas do SAPL e valida a instância quando encontra marcadores compatíveis. Em seguida, a extração deriva a base correta

Pipeline do Sonar Municipal

Da descoberta de fontes à interface pública de busca e exploração de políticas similares




Figura 1. Síntese do pipeline do Sonar Municipal, da descoberta de fontes à interface pública.

da API, consulta os tipos de matéria e percorre a paginação de todos os tipos cujo rótulo contém “projeto de lei”.

Na execução congelada em 12 de novembro de 2025, foram encontradas 1.259 instâncias do SAPL, das quais 322 permitiram extração válida com ao menos um PL, totalizando 220.065 registros. Considerando os 5.570 municípios brasileiros, isso corresponde a 22,60% de cobertura na descoberta e 5,78% na extração automatizada. A diferença entre essas etapas reflete heterogeneidade técnica entre portais, mudanças de rota, autenticação e diferenças locais de configuração. Assim, a descoberta operou em escopo nacional, mas a base extraída deve ser interpretada como um subconjunto parcial e desigual dos municípios com instâncias SAPL acessíveis.

A base final cobre 322 municípios em 19 UFs. Todos os registros possuem ementa, ação, endereço público de origem e representação vetorial preenchidos. A base não apresentou duplicatas nem no endereço público nem na combinação entre a instância SAPL de origem e o identificador da matéria. O filtro textual de tipos, contudo, ainda recupera cerca de 3,54% de itens que não correspondem estritamente a PLs, como anteprojeto, emendas, substitutivos e vetos. Esses casos foram mantidos como ruído residual de coleta, sem a pretensão de que a base represente apenas PLs estritos.

3.3. Textualização de ementas

Para reduzir ruído jurídico e tornar as proposições mais comparáveis, cada ementa é convertida em uma ação textualizada no formato “verbo no infinitivo + objeto + complementos essenciais”. O conjunto de treinamento foi composto por 1.000 ementas reais distintas, textualizadas com apoio de GPT-5.1-Thinking [8] e revisadas manualmente nos casos em que houve perda de sentido.

Como modelo base, utilizou-se o PTT5-v2 [9], uma variante do T5 [10] adaptada

ao português. O ajuste fino foi realizado com QLoRA em 4 bits [11], com divisão 90/10 entre treino e validação, 30 épocas, taxa de aprendizado de 3×10^{-4} e tamanho de lote igual a 16. A avaliação automática por BERTScore [12] atingiu 84% no conjunto de validação.

No acervo completo, a tradução reduziu o comprimento médio das descrições de 152,86 para 90,01 caracteres e de 24,18 para 13,61 palavras. Isso corresponde a 58,9% dos caracteres e a 56,3% das palavras das ementas originais, o que favorece busca e agrupamento. A textualização foi mantida por três razões operacionais. Primeiro, o modelo de representações vetoriais não foi treinado especificamente em texto legislativo. Segundo, ações curtas são mais legíveis para o usuário final do que ementas jurídicas. Terceiro, o agrupamento por similaridade textual tende a funcionar melhor quando há menos ruído introduzido por fórmulas legislativas recorrentes.

3.4. Busca, indicadores e agrupamento

As ações são indexadas com representações vetoriais do modelo Multilingual E5 [13] e armazenadas no Qdrant [14]. As consultas seguem o formato recomendado pelo modelo para entradas de busca. Para avaliar o efeito da textualização na recuperação, comparamos três variantes do mesmo acervo: um *baseline* lexical BM25 sobre as *ementas* originais, busca semântica sobre as *ementas* originais e busca semântica sobre as *ações* textualizadas. O benchmark exploratório foi composto por 15 problemas plausíveis para a plataforma, formulados como necessidades municipais, e por um pool anotado derivado da união dos top-30 das três abordagens. Cada par problema-documento recebeu julgamento automatizado de relevância em escala de 0 a 3 por um agente GPT-5.4, totalizando 1.158 anotações e média de 77,2 candidatos por problema.

Sobre esse pool calculamos P@K, Recall@10, MRR@10, MAP@10, nDCG e métricas restritas a documentos fortemente relevantes (*relevance* ≥ 2). Em termos de interpretação, P@K mede a fração de itens úteis nas primeiras posições; Recall@10 mede quantos itens relevantes do pool aparecem no top-10; MRR@10 privilegia a posição do primeiro acerto; MAP@10 resume precisão e ordenação ao longo do ranking; e nDCG usa relevância graduada para premiar listas que colocam os melhores documentos mais cedo. As métricas “High” repetem essa lógica considerando apenas documentos com relevância alta. Como o conjunto anotado deriva da união dos rankings comparados, a avaliação mede qualidade relativa de ordenação e cobertura local do top-30 anotado, e não *recall* absoluto no corpus completo. Em outras palavras, o experimento responde com mais segurança à pergunta “ações e ementas superam o *baseline* lexical neste pool avaliado?” do que à pergunta mais forte sobre superioridade robusta e universal no corpus real.

O uso de GPT-5.4 nessa etapa teve finalidade instrumental: padronizar os julgamentos de relevância e viabilizar uma comparação rápida entre métodos. Esse agente não substitui avaliadores humanos especialistas nos domínios substantivos cobertos pelas consultas, mas sua saída já fornece uma referência base consistente para comparar a qualidade relativa entre *bm25*, *ementas* e *ações*.

Para aproximar o sistema de desfechos observáveis, utilizamos taxa de homicídios por 100 mil habitantes e taxa de matrículas em ensino regular por 100 mil habitantes. As variações são calculadas comparando o indicador na data mais próxima ao PL com janelas

posteriores de 6, 12, 18, 24, 30 e 36 meses. Trata-se de uma análise descritiva, sem pretensão causal, utilizada apenas para priorização exploratória de políticas recorrentes.

PLs semanticamente próximos são agrupados por similaridade de Jaccard sobre o texto da ação, com limiar 0,75. Para cada grupo, definimos o seguinte escore heurístico:

$$Q = \frac{p}{n} \times \frac{n}{n+1}$$

em que n é o número de municípios representados e p é o número de casos com variação favorável ao objetivo do indicador. O termo final penaliza grupos muito pequenos e ajuda a priorizar políticas mais recorrentes.

3.5. Implementação

A plataforma foi implementada em React/Next.js e integra interface web, serviço de geração de representações vetoriais, banco vetorial e dados de indicadores [15]. O código de coleta, treinamento, indexação e interface permanece disponível em <https://github.com/thiagoambiel/SonarMunicipal>, juntamente com o prompt do tradutor e a lista congelada de instâncias SAPL utilizadas no artigo. A implementação web pública está disponível em <https://sonar-municipal.vercel.app/>. A reprodução integral do acervo depende da disponibilidade externa das APIs públicas no momento da coleta, mas o repositório documenta as etapas e disponibiliza os artefatos necessários para reexecução.

4. Resultados

4.1. Cobertura da base

A execução congelada indica que a descoberta nacional é tecnicamente viável, mas que a extração automatizada ainda depende fortemente da qualidade e da estabilidade das instâncias municipais do SAPL. A Figura 2 resume os principais números dessa execução como painel visual de escala, redução e concentração regional.

Em termos percentuais, o Sul concentra 45,52% dos registros e o Sudeste, 23,03%; juntas, essas duas regiões somam 68,55% do acervo e 64,29% dos municípios cobertos. A Figura 2 antecipa essa leitura quantitativa, e a Figura 3 mostra sua distribuição territorial, com cobertura concentrada em 19 UFs e lacunas visíveis em parte do Norte e do Nordeste. O resultado deve ser interpretado como um acervo interestadual extenso, mas não como um espelho nacional da produção legislativa municipal. A base cobre principalmente o período recente da produção legislativa: entre 2021 e 2025, há 96.018 registros distribuídos por 315 municípios. Também foram observados poucos outliers temporais, o que indica necessidade de saneamento antes de análises mais sensíveis ao eixo cronológico.

4.2. Tradução e busca semântica

Viabilidade da textualização. Na avaliação interna do projeto, o tradutor *ementa* → *ação* obteve BERTScore de 84% no conjunto de validação. A transformação de todo o acervo de 220.065 PLs em ações textualizadas levou 4h47min na execução reportada, o que indica viabilidade operacional nessa escala.



Figura 2. Painel visual da execução congelada, combinando indicadores-chave, redução do pipeline e distribuição regional do acervo final.

A análise exploratória da base mostrou que a textualização reduz substancialmente o comprimento médio das descrições legislativas sem eliminar a diversidade do acervo. Foram observadas 219.245 ementas únicas e 188.254 ações textualizadas únicas. Em termos práticos, a transformação encurta o texto e reduz variabilidade superficial suficiente para favorecer recuperação semântica e agrupamento; exemplos típicos incluem conversões como “Institui o Plano Municipal de Saneamento Básico” para “Criar plano municipal de saneamento básico”.

Avaliação anotada da recuperação. A comparação formal entre *bm25*, *ementas* e *ações* foi conduzida em 15 problemas municipais com 1.158 pares problema-documento anotados automaticamente por um agente GPT-5.4. Para esta subseção, tratamos *nDCG@10* e *High-Recall@10* como métricas primárias, por combinarem ordenação graduada e cobertura local de documentos fortemente relevantes; *MAP@10* e *P@10* entram como métricas secundárias de apoio. O pool continua denso em itens úteis porque foi construído da união dos top-30 das três abordagens: 75,6% dos itens receberam relevância maior que zero e 54,9% receberam relevância alta (≥ 2). No recorte por método, *ações* concentrou a maior fração de itens fortemente relevantes no pool (68,0%), acima de *ementas* (55,6%) e do *baseline* lexical BM25 (52,7%). Mesmo entre os candidatos exclusivos, *ações* permaneceu mais forte: 62,1% dos itens exclusivos de *ações* receberam relevância alta, contra 45,8% dos exclusivos de *ementas* e 44,7% dos exclusivos de BM25. As Figuras 4, 5 e 6 separam essa comparação em três leituras complementares: heterogeneidade por problema, deltas relativos ao baseline lexical e resumo agregado com incerteza.

Em termos operacionais, o agente GPT-5.4 atribuiu relevância em escala ordinal de 0 a 3, em que 0 indica irrelevância, 1 indica relevância básica, 2 indica relevância alta e




Figura 3. Cobertura territorial da base final por UF. Estados em cinza não tiveram extração válida na execução congelada; a intensidade do azul indica o número de municípios cobertos em cada UF.

Tabela 1. Resumo agregado das métricas principais no benchmark anotado.

Métrica	BM25	Ementas	Ações
nDCG@10	0,522	0,591	0,743
High-Recall@10	0,145	0,165	0,215
MAP@10	0,125	0,142	0,173
P@10	0,787	0,873	0,940

3 indica forte aderência ao problema formulado na consulta. O julgamento foi guiado por um prompt fixo e pelo mesmo critério de consistência ao longo de todo o pool, tratando como “fortemente relevante” qualquer item com *relevance* ≥ 2 . O prompt e os artefatos do benchmark são mantidos no repositório do projeto para auditoria e reuso.

Em métricas agregadas, *ações* liderou de forma consistente, seguida por *ementas* e depois por BM25. O ganho aparece tanto na ordenação quanto na composição do ranking: nDCG@10 foi de 0,522 em BM25 para 0,591 em *ementas* e 0,743 em *ações*; MAP@10, de 0,125 para 0,142 e 0,173; e a relevância média no top-10, de 1,773 para 1,940 e 2,327. Em termos práticos, isso significa que a textualização em formato de ação não apenas encontra mais itens úteis do que o baseline lexical, mas também coloca documentos mais fortemente alinhados nas primeiras posições. No topo do ranking, a melhora também é visível: P@10 sobe de 0,787 em BM25 para 0,873 em *ementas* e 0,940 em *ações*. O efeito mais consistente, porém, aparece na recuperação de documentos fortemente relevantes: High-P@10 sobe de 0,620 em BM25 para 0,640 em *ementas* e 0,793 em *ações*, enquanto High-Recall@10 passa de 0,145 para 0,165 e 0,215.

Essa decomposição ajuda a separar mais claramente três efeitos. Primeiro, há um

Comparação por problema em nDCG@10

Cada linha liga o baseline lexical BM25, a busca por ementas e a busca por ações textualizadas; os problemas estão ordenados pela distância entre ações e BM25, do maior para o menor.




Figura 4. Comparação de nDCG@10 por problema entre o baseline lexical BM25, a busca semântica por ementas e a busca semântica por ações textualizadas. Cada linha representa uma consulta, ordenada pela distância entre ações e BM25, do maior para o menor. A figura destaca que a vantagem média de ações é ampla, mas não uniforme, com perdas concentradas em consultas mais terminológicas.

efeito de **ordenação**, capturado por nDCG@10 e MAP@10, em que *ações* abre vantagem média consistente. Segundo, há um efeito no **topo do ranking**, visível em P@10 e High-P@10, indicando listas iniciais mais limpas e úteis. Terceiro, há um efeito de **cobertura local do pool**, observado em Recall@10 e High-Recall@10, que sugere maior recuperação de documentos fortemente relevantes dentro do universo anotado. Essa interpretação é compatível com a hipótese de que a textualização reduz ambiguidade e aproxima a indexação de consultas formuladas como objetivos de política pública, mas essa explicação deve ser lida como hipótese interpretativa e não como mecanismo causal demonstrado.

O perfil pareado por problema reforça essa leitura e mostra heterogeneidade substantiva que a média sozinha esconde. Contra o baseline lexical, *ações* venceu em 11 das 13 comparações não empatadas tanto em High-P@10 quanto em High-Recall@10, com *sign test* exato de $p = 0,022$ em ambas as métricas. Em nDCG@10, *ações* ficou à frente de BM25 em 13 dos 15 problemas, com apenas duas derrotas; *ementas*, por sua vez, venceu BM25 em nove dos 15 problemas. Além disso, os três rankings recuperam conjuntos parcialmente distintos: o overlap médio entre BM25 e *ementas* é de 4,27 documentos por

Delta por problema e por métrica

Ganho relativo ao baseline lexical BM25, separando métricas de ordenação (nDCG, MAP) e de desempenho no topo e na cobertura local (P@10, H-Recall).




Figura 5. Delta relativo ao baseline lexical BM25, por problema e por métrica. O painel esquerdo mostra *ementas* – BM25; o direito, *ações* – BM25. Tons azuis indicam ganho e tons terracota indicam perda. O ponto a observar é que os ganhos de ações são mais frequentes e mais intensos nas métricas de ordenação e cobertura local, embora não se distribuam uniformemente entre todos os temas.

problema (Jaccard 0,083), entre BM25 e *ações* é de 4,47 (0,088) e entre *ementas* e *ações* é de 6,20 (0,126). Na prática, isso indica que a recuperação semântica altera materialmente quais PLs chegam ao usuário, e não apenas a ordem de um mesmo conjunto. Como esses julgamentos foram produzidos por GPT-5.4, os números devem ser lidos como uma linha de base automatizada para comparação relativa entre métodos, e não como veredicto final de especialistas setoriais. Essa leitura também permanece restrita a um contraste entre um baseline lexical simples e duas variantes semânticas do mesmo acervo, já que *baselines* híbridos e métodos de fusão ainda não foram incluídos neste benchmark.

Os maiores ganhos de *ações* sobre o baseline apareceram em enchentes urbanas (nDCG@10 de 0,000 para 0,964), arrecadação sem subir impostos (0,181 para 0,642), resíduos e reciclagem (0,495 para 0,946), inclusão de pessoas com deficiência (0,374 para 0,789) e iluminação pública (0,167 para 0,460). Nesses casos, a textualização parece reduzir ambiguidade e aproximar a indexação de consultas formuladas como objetivos de política pública. As principais perdas frente ao BM25 ocorreram em mobilidade no horário de pico (0,607 para 0,404) e digitalização de serviços (0,455 para 0,382), sugerindo que consultas mais terminológicas ou fortemente ancoradas em vocabulário literal ainda podem favorecer o baseline lexical.

Resumo agregado com incerteza

Os pontos mostram o ganho médio sobre o BM25; as barras representam IC bootstrap de 95% entre consultas.




Figura 6. Ganho médio por consulta com IC 95% por *bootstrap* entre consultas para *ementas* e *ações* em relação ao baseline lexical BM25, além da contagem de vitórias, empates e derrotas por problema. A figura resume a comparação relativa no pool anotado e explicita a incerteza e a variabilidade entre problemas.

Essa heterogeneidade sugere uma leitura mais precisa do resultado. A evidência observada aqui não é de superioridade universal da textualização, mas de vantagem média no benchmark avaliado, com efeito heterogêneo entre temas e ganho mais frequente em consultas formuladas como objetivo de política pública. Em contrapartida, consultas mais terminológicas ou domínios em que a ementa já preserva vocabulário técnico claro podem perder desempenho quando a reescrita simplifica demais o conteúdo. O benchmark mede qualidade relativa de ordenação e cobertura local dentro do pool anotado; ele não mede *recall* absoluto no corpus inteiro nem resolve sozinho a questão da generalização externa. Como próximo passo metodológico, planejamos validação estratificada em subconjuntos de maior discordância entre métodos e em consultas com maior sensibilidade temática, complementando a linha de base automatizada com revisão humana focalizada. Em síntese, os resultados sustentam vantagem média da recuperação baseada em ações no pool anotado, especialmente em métricas que combinam relevância graduada e cobertura de itens fortemente relevantes, mas essa vantagem não é uniforme entre temas e deve ser interpretada à luz do caráter exploratório do benchmark. Apesar de promissores, esses achados devem ser lidos em conjunto com as ameaças à validade discutidas na Seção 5.

4.3. Estudo de caso: violência contra a mulher

Entre os temas disponíveis no acervo, violência contra a mulher foi selecionado como estudo de caso principal. O recorte lexical correspondente reúne 2.306 ações distribuídas por 204 municípios e 18 UFs. Esse volume foi considerado adequado para ilustrar o fluxo completo do sistema, desde a consulta em linguagem natural até a consolidação de políticas recorrentes. A Figura 7 sintetiza esse percurso visualmente. Por razões de disponibilidade e cobertura, adotou-se a taxa de homicídios como proxy inicial deste estudo de caso, exclusivamente para fins exploratórios de priorização.



Figura 7. Fluxo completo do estudo de caso sobre violência contra a mulher, da consulta em linguagem natural à priorização exploratória de políticas recorrentes.

No recorte temático com janela de 6 meses para taxa de homicídios, 1.240 ações tiveram variação computável e geraram 136 políticas agrupadas com pelo menos dois municípios. O cluster com maior score heurístico foi “Conceder auxílio financeiro a mulheres vítimas de violência doméstica no município”, com $Q = 0,778$, oito municípios representados e sete variações favoráveis em oito observações. Entre os exemplos que compõem esse grupo estão Marabá, Campina Grande e Campinas, com reduções observadas de -26,23%, -22,22% e -30,00%, respectivamente. Esses resultados devem ser interpretados como associações observadas após a proposição legislativa, e não como evidência causal de efetividade.


Além do cluster líder, o estudo de caso indica diversidade de estratégias. Entre os grupos com $Q = 0,750$, apareceram propostas de tramitação prioritária para processos envolvendo vítimas de violência doméstica, programas de defesa pessoal para mulheres, programas municipais de enfrentamento ao feminicídio e mecanismos de punição administrativa para autores de violência contra a mulher. Também apareceu um grupo educacional recorrente: ensino de noções básicas sobre a Lei Maria da Penha nas escolas municipais, com oito municípios e $Q = 0,667$. A Figura 8 organiza esse conjunto como mosaico visual de respostas recorrentes.

4.4. Falhas observadas

A inspeção qualitativa apontou dois riscos recorrentes. Na textualização, a condensação pode alterar o sentido material da proposta quando o modelo força uma paráfrase inadequada, como em “Junho Violeta” → “Junho Violento”. Nos indicadores, variações de -100% em janelas futuras com contagem zero podem parecer excessivamente favoráveis em municípios pequenos ou com baixa contagem absoluta de eventos.

Estratégias recorrentes identificadas no estudo de caso

O sistema recupera respostas econômicas, educacionais, administrativas e protetivas.



Diversidade de estratégias, sem concentração em uma única família de resposta.

Figura 8. Estratégias recorrentes identificadas no estudo de caso, destacando o cluster líder e a diversidade de respostas econômicas, educacionais, administrativas e protetivas.

5. Limitações e Ameaças à Validade

O trabalho apresenta quatro limitações principais. Primeiro, a cobertura da coleta depende da infraestrutura digital das câmaras municipais, o que introduz viés regional e institucional. Segundo, a avaliação do tradutor ainda carece de conjunto de teste independente e análise mais sistemática dos casos em que a reescrita perde nuances importantes do texto legislativo original. O benchmark de recuperação já inclui um *baseline* lexical BM25 e estimativas simples de incerteza por *bootstrap*, mas ainda faltam *baselines* híbridos, métodos de fusão e validação humana parcial dos erros mais críticos. Terceiro, embora agora exista um benchmark anotado de recuperação mais amplo, ele continua exploratório: cobre apenas 15 problemas, usa um pool derivado da união dos top-30 comparados, não estima *recall* absoluto no corpus e foi julgado por um agente GPT-5.4, e não por especialistas humanos dos temas analisados. Isso reduz o custo de avaliação e fornece uma referência base padronizada para comparação entre métodos, mas não equivale a uma validação substantiva qualificada. Também faltam elementos importantes para uma seção de recuperação mais robusta, como mais problemas, candidatos adicionais fora do pool endógeno e validação estratificada com avaliadores humanos. Quarto, a análise com indicadores é observacional, sensível à qualidade temporal da base e insuficiente para sustentar inferência causal. A proxy educacional baseada em matrículas, o uso de homicídios no estudo de caso, o agrupamento textual por Jaccard e o ruído residual da base devem ser entendidos como simplificações de uma avaliação inicial. Em uso institucional, o sistema deve funcionar apenas como apoio exploratório, com validação humana e contextualização local antes de qualquer adoção, adaptação ou priorização administrativa.

6. Conclusão

Este artigo apresentou uma infraestrutura reprodutível para descoberta de instâncias do SAPL, extração de PLs, tradução de ementas em ações textualizadas, busca semântica e associação exploratória com indicadores oficiais municipais. Na execução congelada de 12 de novembro de 2025, o sistema encontrou 1.259 instâncias do SAPL, extraiu PLs de 322 delas e reuniu um acervo de 220.065 proposições distribuídas por 322 municípios e 19 UFs. Os resultados demonstram viabilidade técnica para descoberta em escopo nacional, textualização em escala e utilidade prática da busca semântica quando a indexação usa ações textualizadas. No benchmark automatizado com 15 problemas e 1.158 julgamentos produzidos por um agente GPT-5.4, *ações* foi a melhor representação, *ementas* ficou em segundo lugar e o baseline lexical BM25 permaneceu competitivo, mas inferior em média. Em nDCG@10, por exemplo, os valores médios foram 0,522 para BM25, 0,591 para *ementas* e 0,743 para *ações*; em MAP@10, 0,125, 0,142 e 0,173, respectivamente. A leitura mais segura desses resultados, porém, é de vantagem média no benchmark exploratório avaliado, e não de superioridade universal para qualquer domínio ou consulta. Mesmo sem substituir avaliação humana especializada, essa linha de base automatizada já oferece referência suficiente para comparar a qualidade relativa entre recuperação lexical e semântica. O próximo passo é ampliar o benchmark com mais problemas e avaliadores, incluir *baselines* híbridos e de fusão, reduzir a endogeneidade do pool de avaliação e aumentar o controle sobre ruídos da base e das métricas observacionais.

Referências

- [1] Senado Federal e Programa Interlegis. *Sistema de Apoio ao Processo Legislativo (SAPL)*. URL: <https://www12.senado.leg.br/interlegis/produtos/sapl> (acesso em 07/01/2026).
- [2] Ellen Souza et al. “Assessing the Impact of Stemming Algorithms Applied to Brazilian Legislative Documents Retrieval”. Em: *Proceedings of the 13th Brazilian Symposium in Information and Human Language Technology*. Porto Alegre, Brazil: Association for Computational Linguistics, 2021, pp. 227–236. URL: <https://aclanthology.org/2021.stil-1.25/> (acesso em 15/03/2026).
- [3] Ellen Souza et al. “An Information Retrieval Pipeline for Legislative Documents from the Brazilian Chamber of Deputies”. Em: *Legal Knowledge and Information Systems*. Vol. 346. Frontiers in Artificial Intelligence and Applications. IOS Press, 2021, pp. 119–126. DOI: 10.3233/FAIA210326. URL: <https://doi.org/10.3233/FAIA210326> (acesso em 15/03/2026).
- [4] Douglas Vitória et al. “Building a Relevance Feedback Corpus for Legal Information Retrieval in the Real-Case Scenario of the Brazilian Chamber of Deputies”. Em: *Language Resources and Evaluation* 59.2 (2025), pp. 1257–1277. DOI: 10.1007/S10579-024-09767-3. URL: <https://dblp.org/rec/journals/lre/VitorioSMSCOA25> (acesso em 15/03/2026).
- [5] Charles R. Shipan e Craig Volden. “The Mechanisms of Policy Diffusion”. Em: *American Journal of Political Science* 52.4 (2008), pp. 840–857. DOI: 10.1111/j.1540-5907.2008.00346.x.

- [6] Hidemberg Oliveira Albuquerque, Rosimeire Costa, Gabriel Dalforno Silvestre et al. “UlyssesNER-Br: A Corpus of Brazilian Legislative Documents for Named Entity Recognition”. Em: *Computational Processing of the Portuguese Language: 15th International Conference, PROPOR 2022, Fortaleza, Brazil, March 21–23, 2022, Proceedings*. Vol. 13208. Lecture Notes in Computer Science. Springer, 2022, pp. 3–14. DOI: 10.1007/978-3-030-98305-5_1. URL: https://doi.org/10.1007/978-3-030-98305-5_1 (acesso em 15/03/2026).
- [7] IBGE. *API de Localidades (documentação)*. URL: <https://servicodados.ibge.gov.br/api/docs/localidades> (acesso em 07/01/2026).
- [8] OpenAI. *GPT-5.1 Model (OpenAI API)*. 2026. URL: <https://platform.openai.com/docs/models/gpt-5.1> (acesso em 07/01/2026).
- [9] Marcos Piau, Matheus P. Vieira et al. “PTT5-v2: A Closer Look at Continued Pretraining of T5 Models for the Portuguese Language”. Em: *arXiv* (2024). URL: <https://arxiv.org/abs/2406.10806> (acesso em 07/01/2026).
- [10] Colin Raffel et al. “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”. Em: *Journal of Machine Learning Research* 21.140 (2020), pp. 1–67. URL: <https://jmlr.org/papers/v21/20-074.html> (acesso em 07/01/2026).
- [11] Tim Dettmers et al. “QLoRA: Efficient Finetuning of Quantized LLMs”. Em: *arXiv* (2023). URL: <https://arxiv.org/abs/2305.14314> (acesso em 07/01/2026).
- [12] Tianyi Zhang et al. “BERTScore: Evaluating Text Generation with BERT”. Em: *arXiv* (2019). URL: <https://arxiv.org/abs/1904.09675> (acesso em 07/01/2026).
- [13] Liang Wang et al. “Multilingual E5 Text Embeddings: A Technical Report”. Em: *arXiv* (2024). URL: <https://arxiv.org/abs/2402.05672> (acesso em 07/01/2026).
- [14] Qdrant. *Qdrant Documentation*. URL: <https://qdrant.tech/documentation/> (acesso em 07/01/2026).
- [15] Vercel. *Next.js on Vercel (documentação)*. URL: <https://vercel.com/docs/frameworks/full-stack/nextjs> (acesso em 07/01/2026).